

Guía de Aprendizaje No. 1: Datos, Información, Fuentes, Formatos y Toma de Decisiones

Maria Jose Calderin Franco

Julián Daniel Ladino Arroyo

Maria Camila Chacua Ibarguen

SENA

Centro de Materiales y Ensayos

Técnico en Procesamiento de Datos para Modelos de Inteligencia Artificial

Ficha: 3602991

Ing. Nathalia Martínez Vargas

6 de noviembre de 2026

2.1 Actividades de reflexión inicial

Tabla 1

Diferencias estructurales y límites de almacenamiento entre CSV, XLS y XLSX

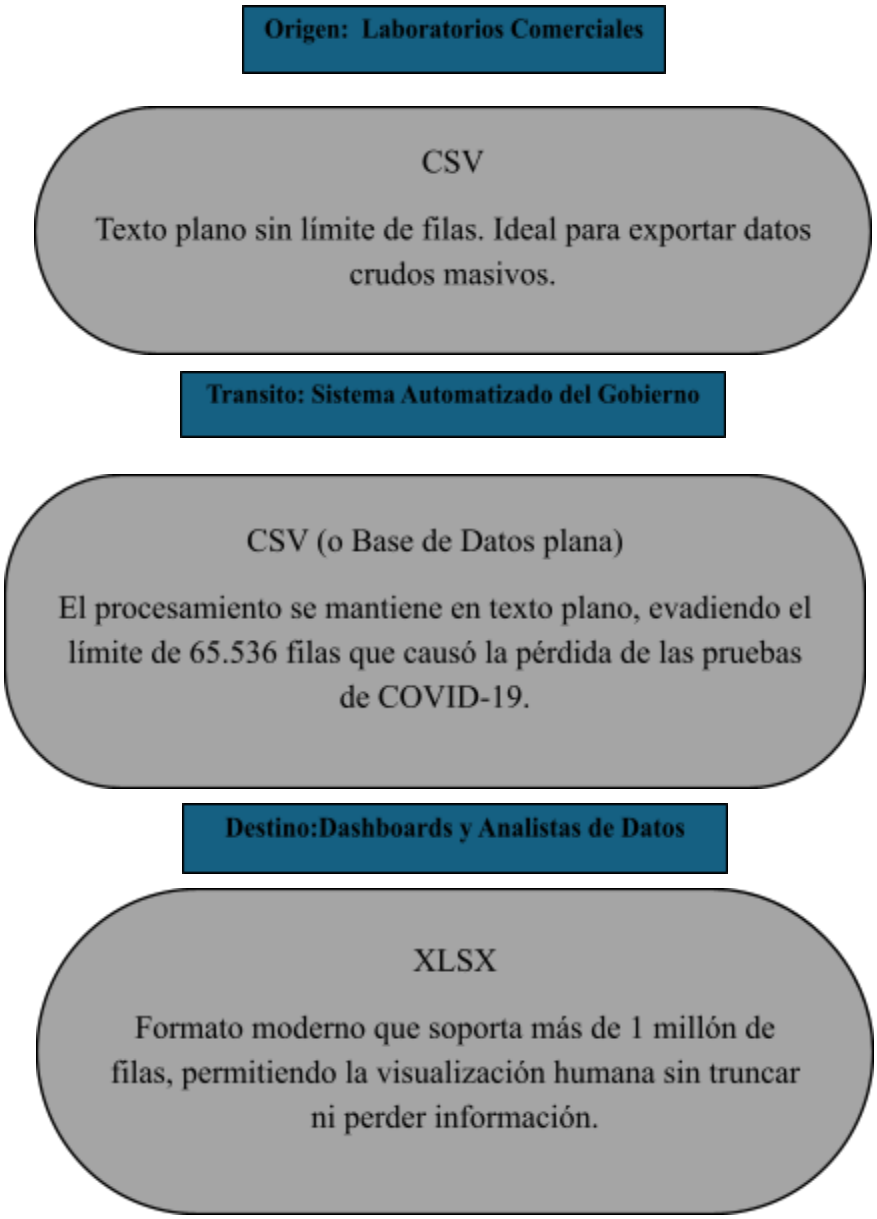
CARACTERÍSTICAS	CSV	XLS	XLSX
FORMATO	Es solo un archivo de texto ligero, de fácil lectura de lenguaje. Este se basa en filas separadas por comas y puntos.	Es un antiguo formato de archivo binario con varias hojas de cálculo. Los archivos están codificados en Excel y no pueden ser leídos fácilmente por otros programas.	Es un nuevo formato con varias hojas de cálculo. El archivo está mejor comprimido, estructurado y tiene mayor compatibilidad con otros programas.
CONTENIDO	Solo almacena datos de forma plana, sin fórmulas, colores, fuentes, gráficos, ni múltiples pestañas o hojas	Este almacena hojas de cálculo completas, con fórmulas, gráficos, texto. Este tiene más atractivos	Este almacena hojas de cálculo completas, con fórmulas, gráficos, texto. Este tiene más

		visuales y cuenta con varias hojas en un mismo archivo	atractivos visuales y cuenta con varias hojas en un mismo archivo
LIMITACIONES	No cuenta con estilos, no cuenta con conexiones automáticas, no cuenta con una propia seguridad	Cuenta con una limitación de filas: 65.536 Limitación de columnas 256 Límite de celdas totales 16.777.216 celdas por hoja. Limite de celdas de 32.767 Soporta un máximo de 4.000 estilos Es muy antiguo y en algunos casos obsoleto e incompatibles	Límites de dimensiones y celdas • Filas por hoja: 1.048.576 filas • Columnas por hoja: 16.384 columnas (de la A a la XFD) • Celdas totales por hoja: 17.179.869.184 celdas • Caracteres por celda: 32.767 caracteres (se visualizan hasta 1.024 en la celda; el resto se ve en la barra de fórmulas)

			• Longitud del nombre de la hoja: 31 caracteres • Longitud de la ruta y nombre del archivo: 218 caracteres
USOS IDEALES	Transferencias de datos de un fácil uso de sistema a sistema, subir o transferir grandes cantidades de datos, leer y procesar rápidamente con herramientas de programación.	facilita la creación de estados de cuenta, control de ingresos y gastos personales o empresariales, mantener controlado las entradas y la salidas mercantiles, informes utilizando funciones estadísticas, filtros de tablas dinámicas, conversión de grandes columnas de datos numéricos en gráficos de barras estas facilitan las toma de decisiones, control de asistencias, nóminas	Organización de volúmenes grandes de información, facilidad de lectura de dispositivos, elaboración de estados financieros, control de ingresos, gastos y flujos de caja,autonomía y facilidad de poder aprender.

Nota: Esta tabla documenta a detalle las diferencias estructurales de los tipos de archivos CVS, XLS yXLSX, y sus límites máximos basados en las especificaciones oficiales de Microsoft Excel. El caso expuesto evidencia una pérdida de datos al superar el límite del formato utilizado, el error se cometió porque se automatizó la carga de datos utilizando el formato heredado XLS. El volumen de resultados de pruebas de COVID-19 superó la limitación técnica de 65.536 filas de este formato, por lo que el sistema simplemente cortó los datos sobrantes sin generar ningún mensaje de alerta o error.

2. Esquema conceptual del tránsito seguro de la información.



3. Conclusión analítica sobre conocimiento técnico y responsabilidad ética.

El caso de Public Health England da evidencia que el conocimiento técnico de un analista de datos a su responsabilidad ética. Como se observó en la gestión de la pandemia, el desconocimiento sobre las limitaciones del formato obsoleto frente a grandes magnitudes de datos desencadenó un error catastrófico. Esta falla técnica generó información errónea que ocultó el nivel real de contagio del COVID-19, impidiendo que el gobierno y el sistema de salud tomarán las precauciones adecuadas en el momento indicado. Al perderse una cifra tan grande de registros simplemente por no aplicar el formato de almacenamiento idóneo, se afectó directamente la vida y seguridad de miles de personas. Por lo tanto, tener más precaución y garantizar la integridad de la información no es solo una tarea operativa, sino un deber ético fundamental para evitar que las decisiones a nivel gerencial y gubernamental se basen en realidades distorsionadas.

2.2 Actividades de contextualización e identificación de conocimientos

1.Selección y justificación del eje temático.

Hemos decidido escoger dos temáticas diferentes: la toma de pruebas y el análisis de resultados para determinar si una persona padece una enfermedad (Diabetes), y qué tipo de tendencias hay en la industria musical global. La combinación de estas dos temáticas nos permite observar, analizar y evaluar datos de distintos ejes: uno enfocado en el ámbito clínico y el otro en el entretenimiento digital.

Los dos datasets escogidos sobre diabetes nos permiten analizar información clave, ya que son de las bases de datos más completas y disponibles para el aprendizaje automático sobre un tema de gran interés; estas contienen más de 100.000 registros de pacientes con más de 180 columnas que abarcan diversos aspectos del diagnóstico clínico. Por su parte, el tercer *dataset* sobre música aborda un tema de interés general y resulta una opción muy conveniente, dado que cuenta con un amplio repertorio de datos en el periodo 2010-2025 con información sólida y lista para ser analizada.

2. Clasificación y justificación del tipo de fuentes de extracción de la información.

Todos los datasets que se emplearon para esta guía corresponden a fuentes de extracción secundaria, debido a que no es información que el equipo haya recolectado personalmente mediante encuestas, entrevistas, experimentos u otros métodos propios, sino que fue tomada de la plataforma Kaggle. Nuestra selección está conformada por datos capturados, procesados y publicados originalmente por profesionales e investigadores de las áreas, lo cual garantiza la validez metodológica y la idoneidad técnica de los registros para su posterior auditoría.

3. Listado de conjuntos de datos descubiertos en la exploración.

Nombre del dataset: Diabetes 💉

- Portal de alojamiento: Kaggle
- Enlace de acceso (URL): https://www.kaggle.com/datasets/datascikhan/diabetes

Nombre del dataset: Diabetes

- Portal de alojamiento: Kaggle
- Enlace de acceso (URL):
- https://www.kaggle.com/datasets/imtkaggleteam/diabetes

Nombre del dataset: What makes a song go viral? 10,000 tracks

- Portal de alojamiento: Kaggle
- Enlace de acceso (URL):

https://www.kaggle.com/datasets/vedauv/what-makes-a-song-go-viral-10000-tracks

4. Tabla estructurada de clasificación de variables estadísticas.

Tabla 2

Clasificación de Variables Según su Categoría Estadística

N	*variable*	*Clasificación*	*Relevancia*
1	height	Cuantitativa continua	Altura del paciente. Permite calcular el IMC para evaluar la obesidad.
2	weight	Cuantitativa continua	Peso del paciente. Junto con la altura permite calcular el IMC, ya que el sobrepeso se relaciona directamente con la resistencia a la insulina.

3	sodium	Cuantitativa continua	Cantidad o nivel de sodio registrado. Está directamente relacionada ya que es un factor de riesgo causante de hipertensión y también es un riesgo para la salud cardiovascular y renal del paciente.
4	physical_activity_level	Cualitativa ordinal	Nivel de actividad física que realiza una persona. Porque el ejercicio hace que las células gasten la glucosa como fuente de energía, lo que permite un mejor control del azúcar en la sangre sin necesidad de tanta insulina.
5	fasting_glucose	Cuantitativa continua	Nivel de glucosa en la sangre después de un periodo de ayuno. Permite conocer el nivel promedio del azúcar en la sangre sin la ingesta previa de alimentos, lo que ayuda a diagnosticar prediabetes o diabetes.
6	sleep	Cualitativa ordinal	Calidad percibida o patrón de descanso nocturno. Ya qué la calidad del sueño influye directamente en el metabolismo y en la hormona reguladora del estrés (cortisol), y

			estos son factores biológicos que pueden regular o desestabilizar la glucosa en la sangre del paciente.
7	fast_food_frequency	Cualitativa ordinal	Número de veces que una persona consume comida rápida. Al ser alimentos ultraprocesados en azúcares, grasas y harinas refinadas , su consumo frecuente aumenta el riesgo de desarrollar resistencia a la insulina y diabetes tipo 2.
8	diabetes_type	Cualitativa nominal	Es el dato concluyente. Un diagnóstico final que se le da al paciente como resultado del análisis de las variables y los exámenes médicos
9	diet_pattern	Cualitativa nominal	El estilo de alimentación que el paciente mantiene de forma regular y sostenida. Permite conocer cómo los hábitos alimenticios del paciente influyen en sus niveles de azúcar y según el análisis poder tratarlo de manera adecuada.
	hemoglobin	Cuantitativa continua	El porcentaje de glóbulos rojos que tienen moléculas de glucosa adheridas. Permite

10			conocer el nivel promedio de glucosa en la sangre del paciente durante los últimos 2 o 3 meses.

N	***variable***	***Clasificación***	***Relevancia***
11	ethnicity	Cualitativa nominal	Grupo étnico al que pertenece el paciente. Ya que la prevalencia de la enfermedad, los tratamientos y el tipo de diabetes pueden variar según las diferencias genéticas de cada etnia.
12	location	Cualitativa nominal	Centro médico o región geográfica donde se tomaron las muestras. Permite comparar y analizar los diferentes registros y métodos de laboratorio de la enfermedad en distintas regiones.
13	bmi_category	Cualitativa ordinal	La clasificación del peso del paciente. Porque la obesidad es de las principales causas de la diabetes tipo 2 y puede afectar directamente la respuesta de su cuerpo a la insulina.
	frame	Cualitativa ordinal	Contextura corporal del paciente. Permite

14			describir su estructura física y complementar el análisis de las medidas corporales.
15	glyhb	Cuantitativa continua	Promedio del azúcar en la sangre. Es la medida más exacta del promedio del nivel de glucosa en la sangre durante los últimos 2 o 3 meses del paciente.
16	id	Cualitativa nominal	Número de identificación del registro del paciente. Permite dar un seguimiento más transparente, seguro y confiable para el paciente.
17	time.ppn	Cuantitativa continua	El registro exacto de cuándo se tomó la muestra o el dato. Es el tiempo que pasó desde la última vez que el paciente ingirió algún alimento de cualquier tipo, previo a la toma de exámenes médicos.
18	gender	Cualitativa nominal	Sexo biológico del paciente. Permite comparar cómo pueden influenciar las hormonas y la distribución de la grasa natural en la enfermedad en ambos géneros.
19	hip	Cuantitativa continua	Medida en centímetros de las caderas del paciente. Es una medida necesaria para

			complementar el análisis físico del paciente y su relación con la enfermedad.
20	ratio	Cuantitativa continua	Relación matemática entre los niveles de glucosa y de insulina en la sangre. Permite calcular de manera precisa el nivel de resistencia a la insulina del paciente.

N	***variable***	***Clasificación***	***Relevancia***
21	track_id,	Cualitativa nominal	Es el identificador único y universal que se le da a una canción, para garantizar que el análisis de los datos por parte de la maquina sea preciso y sin errores.
22	track_name	Cualitativa nominal	Es el identificador humano que se le da a una canción (el nombre), para que los analistas, investigadores o demás sepan de que canción se está hablando sin tener que consultar directamente la base de datos.
23	artist	Cualitativa nominal	Es el nombre del autor. Es un dato importante ya que muchas veces el éxito y la viralidad de una canción depende del contexto social que

			rodea al autor.
24	genre	Cualitativa nominal	Permite comparar y dar una conclusión acerca del comportamiento de la audiencia y los algoritmos de recomendación frente a algunos géneros.
25	release_year	Cuantitativa discreta	Ayuda a identificar tendencias a lo largo del tiempo y a analizar qué tipo de música ha tenido mayor impacto y viralidad en determinados periodos de tiempo.
26	duration_sec	Cuantitativa continua	Permite evaluar si la duración de una canción influye en su éxito, identificando el promedio en segundos de los temas con mayor impacto para determinar si existe un rango de tiempo óptimo que favorezca la viralidad.
27	danceability	Cuantitativa continua	Permite evaluar si el nivel de bailabilidad de una canción influye directamente en su popularidad y en sus posibilidades de volverse viral.
28	streams	Cuantitativa discreta	Permite ver cuántas veces ha sido reproducida una canción.Y con ese dato se puede analizar

			su popularidad y si esta variable influye directamente en su viralidad.
29	viral	Cualitativa nominal	Es el indicador binario que identifica si la canción es viral (1) o no viral (0). Es básicamente el dato final que se concluye a partir del análisis completo de la canción.
30	energy	Cuantitativa continua	Permite evaluar si el nivel de energía e intensidad de una canción influye directamente en su popularidad y en sus posibilidades de volverse viral.

Nota: Clasificación rigurosa de las variables observadas en los datasets del portal Kaggle. Se clasifica según su naturaleza estadística cualitativa (nominal/ordinal) o cuantitativa (discreta/continua).

2.3 Actividades de Apropiación del Conocimiento

Descubrimiento y documentación de inconsistencias halladas en los datos de los datasets seleccionados

- **Error 1**

¿Qué o cuál es el problema?

En el dataset de diabetes, en la columna glyhb, tenemos las casillas F45, F61, F66, F111, F118, F119, F194, F219, F275, F328, F329, F398 y F404 totalmente vacías.

¿Cómo se ha detectado?

Usando el filtrado encontramos estos valores en vacío.

¿Por qué cree que se trata de un problema?

Estos son valores que no lee la inteligencia artificial, por lo que se perderían completamente esas filas, y son datos muy relevantes sobre la enfermedad que se está analizando.

¿Un ejemplo completo extraído del propio dataset?



- **Error 2**

¿Qué o cuál es el problema?

En el dataset de diabetes, las columnas bp.2s y bp.2d tienen 262 valores vacíos cada una.

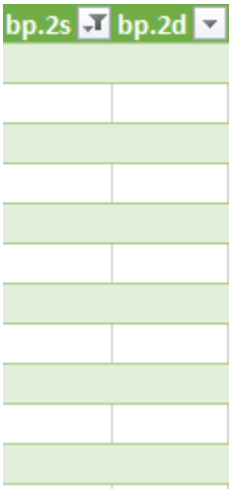
¿Cómo se ha detectado?

Al revisar la estructura de las columnas, se observó que de las 403 filas totales que tiene el archivo, solo 141 pacientes tienen este dato.

¿Por qué cree que se trata de un problema?

Faltan por lo menos el 65% de los datos en estas columnas. Esto hace que pierdan mucho peso estadístico, por lo que es mejor no poner esas casillas en el modelo.

¿Un ejemplo completo extraído del propio dataset?



- **Error 3**

¿Qué o cuál es el problema?

Existen pacientes con niveles de colesterol que no van acorde al ratio.

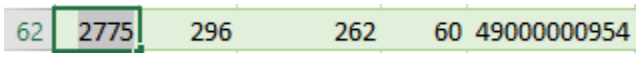
¿Cómo se ha detectado?

Verificamos los datos proporcionados en el dataset y los niveles de colesterol son demasiados altos. Para una persona normal, o incluso con problemas de colesterol alto, son datos ilógicos.

¿Por qué cree que se trata de un problema?

Esos datos son atípicos y distorsionan el promedio general y la varianza. Son datos que no tienen concordancia.

¿Un ejemplo completo extraído del propio dataset?



- **Error 4**

¿Qué o cuál es el problema?

Vemos campos vacíos en la edad, pero en la siguiente casilla vemos datos "completos" dándole un valor a su grupo de edad.

¿Cómo se ha detectado?

Dándonos cuenta en los datos faltantes, observamos que existía una inconsistencia en el tema de age y age_group: existen valores en age_group que no existen en las casillas de age.

¿Por qué cree que se trata de un problema?

Porque una inteligencia artificial no le puede dar concordancia a los valores ya dados si falta el dato principal del que dependen

¿Un ejemplo completo extraído del propio dataset?

	A	B	C	D
1	patient_id	record_id	age	age_group
37	P000036	R00000036		31-40
67	P000066	R00000066		61-70
85	P000084	R00000084		41-50
154	P000153	R00000153		31-40
155	P000154	R00000154		51-60

- **Error 5**

¿Qué o cuál es el problema?

Existen valores que simplemente no tienen sentido.

¿Cómo se ha detectado?

Revisando los datos encontramos valores numéricos que no corresponden a la tabla, tales como: 1,93E+11.

¿Por qué cree que se trata de un problema?

Porque no son datos reales ni coherentes, y esto evita un buen manejo de los datos a la hora de procesarlos.

¿Un ejemplo completo extraído del propio dataset?

2778	443	185	23	1,93E+11	1,431E+11

- **Error 6**

¿Qué o cuál es el problema?

La columna time.ppn tiene registros máximos que resultan ilógicos para un examen de rutina.

¿Cómo se ha detectado?

Organizando la columna time.ppn de mayor a menor y revisando sus valores máximos.

¿Por qué cree que se trata de un problema?

Contamina la calidad del dataset y genera correlaciones falsas al analizar los picos de azúcar en sangre, no siendo coherente para la inteligencia artificial.

¿Un ejemplo completo extraído del propio dataset?

waist	hip	time.ppn
29	39	1560

2.4 Actividades de Transferencia de Conocimiento

2.4.1 Desarrollo del Diccionario de Datos

Utilizamos el dataset de música del usuario (vedauv) en kaggle ("What Makes a Song Go Viral?") siendo el más robusto, viene con 10,000 filas y 17 columnas con datos de género, reproducciones y viralidad.

Tabla 3

Matriz y Diccionario de Datos del Dataset Principal.

Nombre original de la variable	Nombre estandarizado sugerido	Clasificación estadística	Tipo de dato técnico	Descripción semántica	Unidad de medida o formato
patient_id	**id_paciente**	Cualitativa nominal	Cadena de texto	Identificador único y exclusivo de cada paciente en el sistema.	Alfanumérico.
age	**edad_paciente**	Cuantitativa discreta	Numérico entero	Edad cronológica del paciente al momento del estudio.	Años.
gender	**genero_paciente**	Cualitativa nominal	Cadena de texto	Identidad de género biológico o registrado del paciente.	Texto (Male/Female)
education_level	**nivel_educativo**	Cualitativa ordinal	Cadena de texto	Grado máximo de escolaridad alcanzado por el paciente.	Texto
annual_income	**ingreso_anual**	Cuantitativa continua	Numérico decimal	Cantidad de dinero generada por el paciente o su hogar en un año.	Moneda (USD u otra)
urban_rural	**zona_residencia**	Cualitativa nominal	Cadena de texto	Clasificación del entorno de la vivienda (Urbano o Rural).	Texto
height_cm	**estatura**	Cuantitativa continua	Numérico decimal	Altura física del paciente.	Centímetros (cm)
weight_kg	**peso**	Cuantitativa continua	Numérico decimal	Masa corporal total del paciente.	Kilogramos (kg)

bmi	**imc_numerico**	Cuantitativa continua	Numérico decimal	Índice de Masa Corporal, que evalúa la relación entre peso y altura.	Puntuación (kg/m²)
bmi_category	**imc_categoria**	Cuantitativa ordinal	Cadena de texto	Clasificación clínica del paciente según su IMC (Normal, Sobrepeso, Obeso).	Texto
body_fat_percentage	**porcentaje_grasa**	Cuantitativa continua	Numérico decimal	Proporción de grasa en relación con la masa corporal total.	Porcentaje (%)
fasting_glucose_mg_dl	**iglucosa_ayuno**	Cuantitativa continua	Numérico decimal	Nivel de azúcar en la sangre medido tras un periodo de ayuno.	mg/dl
hba1c_percent	**hemoglobina_glicosilada**	Cuantitativa continua	Numérico decimal	Porcentaje de hemoglobina glicosilada, clave para diagnosticar diabetes.	Porcentaje (%)
systolic_bp	**presion_sistolica**	Cuantitativa discreta	Numérico entero	Medida máxima de la presión arterial al contraerse el corazón.	mmHg
diastolic_bp	**presion_diastolica**	Cuantitativa discreta	Numérico entero	Medida mínima de la presión arterial al relajar el corazón.	mmHg
total_cholesterol_mg_dl	**colesterol_total**	Cuantitativa continua	Numérico decimal	Cantidad combinada de lípidos y colesterol en la sangre del paciente.	mg/dL
family_history_diabetes	**antecedente_familiar**	Cualitativa nominal	Booleano / Texto	Indica si existen antecedentes directos de diabetes en la familia.	Yes / No

smoking_status	**habito_fumar**	Cualitativa nominal	Cadena de texto	Condición actual del paciente respecto al consumo de tabaco.	Texto
cigarettes_per_day	**cigarros_diarios**	Cuantitativa discreta	Numérico entero	Cantidad promedio de cigarrillos que el paciente fuma al día.	Unidades
alcohol_use	**consumo_alcohol**	Cualitativa nominal	Booleano / Texto	Indica si el paciente consume bebidas alcohólicas habitualmente.	Yes/ No
daily_steps	**pasos_diarios**	Cuantitativa discreta	Numérico entero	Volumen de actividad física medido en pasos dados en un día normal.	Cantidad
sleep_hours	**horas_sueño**	Cuantitativa continua	Numérico decimal	Cantidad de tiempo promedio que el paciente duerme diariamente.	Horas
daily_calorie_intake	**calorias_diarias**	Cuantitativa discreta	Numérico entero	Consumo energético total estimado a través de la dieta diaria.	Kilocalorías (kcal)
hypertension	**diagnostico_hipertension**	Cualitativa nominal	Booleano / Texto	Confirmación clínica de si el paciente padece hipertensión arterial.	Yes / No
diabetes_medication	**toma_medicamento**	Cualitativa nominal	Booleano / Texto	Indica si el paciente recibe medicación específica para la diabetes.	Yes/ No
medication_adherence_percent	**adherencia_medica**	Cuantitativa continua	Numérico decimal	Porcentaje de cumplimiento del paciente con su tratamiento médico.	Porcentaje (%)

distance_to_healthcare_km	**distancia_hospital**	Cuantitativa continua	Numérico decimal	Distancia desde el hogar del paciente hasta el centro de salud más cercano.	Kilómetros (km)
overall_health_score	**puntaje_salud**	Cuantitativa continua	Numérico decimal	Métrica ponderada que evalúa el estado general de salud del paciente.	Puntuación
diabetes_status	**estado_diabetes**	Cualitativa nominal	Numérico decimal	Codificación numérica que indica si el paciente padece o no la enfermedad.	Código binario (1.0/0.0)
diabetes_type	**tipo_diabetes**	Cualitativa nominal	Cadena de texto	Clasificación del diagnóstico de diabetes (Ej. Tipo 2) o ausencia de la misma.	Texto

Nota: Descripción rigurosa y detallada de la estructura, el significado y las características de las variables del dataset más robusto seleccionado por el equipo de trabajo.

Referencias bibliográficas

Datascikhan. (s. f.). Diabetes [Conjunto de datos]. Publicado por Shair Khan.

Kaggle. https://www.kaggle.com/datasets/datascikhan/diabetes

Kaggle. (s. f.). *Diabetes 2* [Conjunto de datos]. Publicado por Mohamadreza Momeni.

https://www.kaggle.com/datasets/imtkaggleteam/diabetes

Kaggle. (s. f.). *What Makes a Song Go Viral? (10,000 Tracks)*. Publicado por vedauv.
https://www.kaggle.com/datasets/vedauv/what-makes-a-song-go-viral-10000-tracks

Spotify for Developers. (s. f.). *Get Track's Audio Features*. Documentación técnica de Spotify Web API.
https://developer.spotify.com/documentation/web-api/reference/get-audio-features

https://www.cigna.com/es-us/knowledge-center/hw/diabetes-uq1193abc